RAPPORT DE PROJET

Prédiction de la Gravité des Accidents Routiers

Machine Learning & Sécurité Routière

📊 Données: Open Data France (BAAC 2021-2023)

🤘 Méthodologie: Random Forest + Interprétabilité SHAP

🎯 Performance: 79% Accuracy | 81% F1-Score

Décembre 2025

Réalisé par :

Aymane OUTIMJICHT
Ikbal EL KHALIDI
Naoufal BERQUECHA

Table des matières

1. Résumé Exécutif 3
2. Introduction et Contexte 4
2.1. Problématique 4
2.2. Objectifs 4
3. Données et Description 5
3.1. Source : Base BAAC 5
3.2. Structure des Données 5
4. Méthodologie 6
4.1. Chargement et Fusion 6
4.2. Nettoyage des Données 6
Suppression grav = -1 6
Regroupement binaire 7
4.3. Feature Engineering 8
5. Modélisation 8
5.1. Choix du Modèle 8
5.2. Split Train/Test 9
5.3. Optimisation Optuna 9
6. Résultats et Performance 10
6.1. Métriques 10
6.2. Matrice de Confusion 11
6.3. Feature Importance 12
7. Interprétabilité SHAP 14
7.1. Principe 14
7.2. SHAP Summary 14
7.3. SHAP Bar 15
7.4 Interactions SHAP (catv x choc) 15
7.5. Limite catv 17
8. Conclusion 18

1. Résumé Exécutif

Ce projet développe un modèle de Machine Learning capable de prédire la gravité des accidents routiers à partir des données officielles françaises. Avec plus de 50 000 accidents corporels annuels en France, ce travail répond à un enjeu majeur de santé publique.

Performance obtenue : Le modèle Random Forest optimisé atteint 79% d'accuracy et 81% de F1-score. L'analyse SHAP révèle que l'absence de dispositifs de sécurité, la vulnérabilité liée au type de véhicule et la catégorie d'usager sont les principaux facteurs prédictifs.

Impact : Cette approche explicable permet aux décideurs (Sécurité Routière, DREAL) de cibler efficacement leurs actions de prévention et d'adapter les infrastructures.

p

2. Introduction et Contexte

2.1. Problématique

La sécurité routière constitue un enjeu sociétal majeur. Les autorités publiques cherchent à comprendre les facteurs de risque pour mieux cibler leurs actions de prévention et améliorer les infrastructures.

2.2. Objectifs

- Développer un modèle prédictif capable de classifier la gravité (*grave* VS. *non grave*)
- Identifier les facteurs de risque principaux via SHAP
- Garantir la transparence et l'explicabilité pour faciliter l'adoption

3. Données et Description

3.1. Source : Base BAAC

Source : Base annuelle des accidents corporels, https://www.data.gouv.fr/datasets/bases-de-donnees-annuelles-des-accidents-corporels-de-la-circulation-routiere-annees-de-2005-a-2024

Années : 2021, 2022, 2023 (3 années complètes)

Volume total : 419 593 usagers impliqués

3.2. Structure des Données

Les données sont réparties en 4 fichiers CSV par année, chacun décrivant un aspect de l'accident :

- **caractéristiques** : informations générales (date, heure, luminosité).
- **lieux** : environnement routier (type de route, état, vitesse).
- **usagers** : personnes impliquées (âge, sexe, gravité).
- **véhicules** : catégorie du véhicule, type de choc, manœuvre.

En 2023, les fichiers "caractéristiques" et "lieux" comptent environ 54 000 lignes, tandis que "usagers" et "véhicules" en comptent environ 160 000, car un accident peut impliquer plusieurs véhicules et plusieurs personnes.

Fichier	Type	Variables	Nb lignes 2023
caractéristiques	Accident	Date, heure, luminosité	~54 000
lieux	Environnement	Type route, état, vitesse	~54 000
usagers	Personnes	Âge, sexe, gravité	~160 000
véhicules	Véhicules	Catégorie, choc	~160 000

La structure suit le schéma :

1 accident → plusieurs véhicules → plusieurs usagers

Le modèle est donc construit au niveau de l'usager, car la gravité concerne chaque personne individuellement. La fusion via Num_Acc et l'identifiant véhicule permet de regrouper toutes les informations utiles (accident, lieu, véhicule) autour de chaque usager.

4. Méthodologie

4.1. Chargement et Fusion

Les quatre fichiers CSV (Caractéristiques, Lieux, Usagers, Véhicules) sont fusionnés afin de constituer une base d'analyse unique et cohérente. La fusion s'effectue à l'aide de clés communes, principalement *Num_Acc* pour relier un accident à ses informations globales, et *id_vehicule* pour rattacher chaque usager au véhicule correspondant.

Cependant, un défi important réside dans les variations de nommage entre les années — certaines colonnes sont renommées, légèrement modifiées ou absentes selon l'année considérée. Pour éviter toute perte d'information ou incohérence structurelle, nous avons développé une fonction d'harmonisation automatique :

- Elle détecte les colonnes équivalentes, même si leur nom change d'une année à l'autre ;
- Elle renomme de façon standardisée l'ensemble des fichiers importés ;
- Elle supprime ou ajoute les colonnes nécessaires pour garantir un schéma identique sur les trois années utilisées.

Cette approche permet de charger les données annuelles sans erreur, tout en préservant l'intégrité des relations entre les tables. Elle garantit également que la fusion multi-fichier se déroule proprement et que les variables finales sont strictement comparables entre les années.

4.2. Nettoyage des Données

Suppression grav = -1

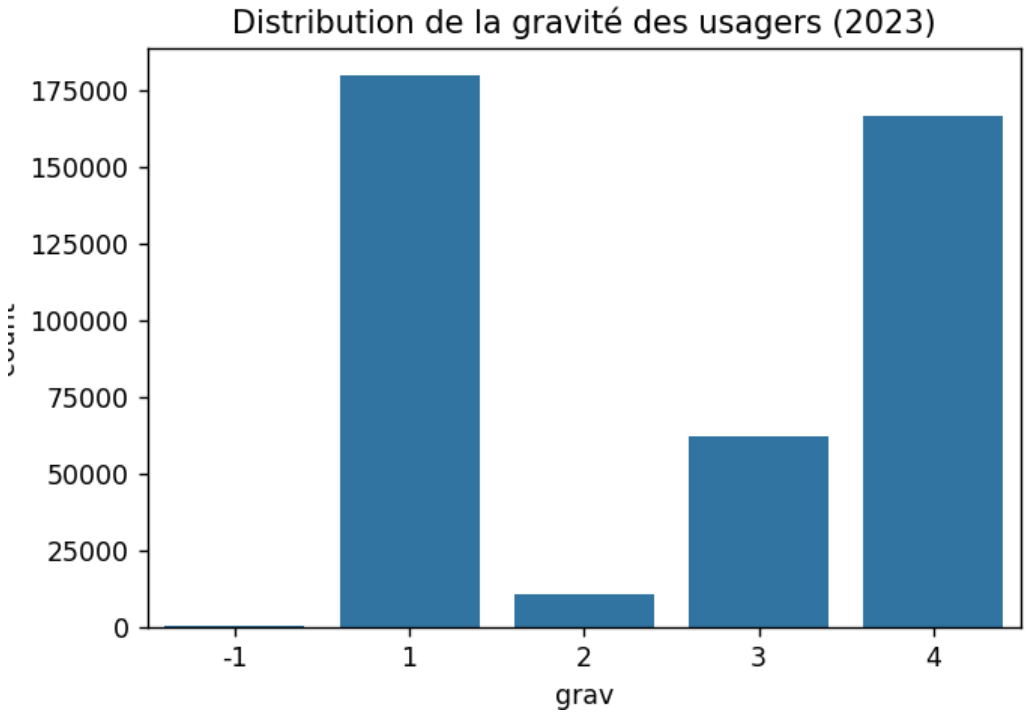
Lors de l'analyse des données brutes, nous observons la présence d'une valeur particulière dans la variable grav : -1, correspondant aux cas où la gravité n'a pas été renseignée. Ce code, défini dans la documentation officielle BAAC, signifie explicitement « information manquante ou non déterminée », et non une catégorie de gravité exploitable.

Afin de garantir la qualité du modèle, nous avons pris la décision de supprimer ces 457 observations, soit seulement 0,11 % du total. Cette suppression repose sur deux arguments essentiels :

1. Justification statistique : le nombre d'occurrences est extrêmement faible, ce qui rend leur impact négligeable sur la représentativité globale du dataset. Conserver ces lignes pourrait introduire du bruit ou entraîner une mauvaise interprétation du modèle lors de l'apprentissage.
2. Justification métier : la gravité constitue la cible de la prédiction. Une observation dont la gravité est inconnue ne peut pas contribuer à l'entraînement du modèle ni être utilisée comme exemple positif ou négatif. Sa présence risquerait de perturber le modèle en lui fournissant des exemples ambigus.

La suppression de ces lignes permet donc d'obtenir un ensemble d'apprentissage propre, cohérent et aligné avec l'objectif prédictif du projet, sans compromettre la représentativité de la base finale.

Regroupement binaire



La variable grav comporte maintenant quatre niveaux (indemne, blessé léger, hospitalisé, tué). Cependant, ces classes sont déséquilibrées et certaines sont très rares, ce qui complique l'apprentissage et rend le modèle instable. Pour améliorer la cohérence du problème et se concentrer sur la notion de gravité réelle, nous avons regroupé les classes en deux catégories :

- 0 = accident non grave (indemne + blessé léger)
- 1 = accident grave (hospitalisé + tué)

Ce choix est aussi justifié d'un point de vue métier : les autorités cherchent principalement à prédire les accidents sévères afin d'identifier les situations les plus dangereuses. Le regroupement permet en plus de rééquilibrer les classes (190 285 non graves vs 228 851 graves), ce qui facilite la construction d'un modèle performant et moins biaisé.

Ancien	Signification	Nouveau
1	Indemne	**0 (faible)**
4	Blessé léger	**0 (faible)**
2	Hospitalisé	**1 (sévère)**
3	Tué	**1 (sévère)**

4.3. Feature Engineering

Sur les 57 variables présentes dans les données brutes, nous en avons conservé 23. Cette sélection repose sur trois critères :

1. Pertinence métier (impact attendu sur la gravité),
2. Taux de remplissage suffisant,
3. Potentiel prédictif selon la littérature et l'expérience terrain.

```
"grav_bin", "grav", "catv", "choc", "manv", "motor", "catu",
        "place", "trajet", "secu1", "secu2", "secu3",
        "lum", "atm", "agg", "int", "col", "surf",
        "mois", "jour", "hrmn",
        "lat", "long",
```

Plusieurs transformations ont été réalisées pour rendre les données plus exploitables :

- Extraction de l'heure : la variable ***hrmn***, codée sous la forme "1325", a été convertie en ***hour*** = 13. Cette simplification permet de capturer plus clairement les tendances temporelles, comme les accidents plus graves la nuit ou aux heures de pointe.
- Géolocalisation : les coordonnées ***lat*** et ***long*** ont été conservées, car elles permettent d'identifier des zones accidentogènes ou des contextes routiers particuliers (urbain, hors agglomération).
- Conservation des variables clés : certaines variables ont été gardées pour leur importance connue dans la sécurité routière, par exemple : ***secu1*** *(port de ceinture/casque),* ***catv*** *(type de véhicule),* ***catu*** *(type d'usager),* ***choc*** *et* ***manv*** *(type de choc et manœuvre),* ***agg*** *et* ***vma*** *(environnement routier et vitesse max),* ***lum*** *et* ***atm*** *(conditions de luminosité et météo).*

Ces choix permettent d'obtenir un jeu de données plus compact, plus propre et surtout mieux adapté à la construction d'un modèle prédictif performant et interprétable.

5. Modélisation

5.1. Choix du Modèle

Pour ce projet, nous avons choisi d'utiliser un Random Forest, un algorithme particulièrement adapté aux données tabulaires comme celles du BAAC. Ce modèle présente plusieurs avantages :

- Excellentes performances sur des données hétérogènes et mixtes (catégorielles + numériques).

- Capacité à capturer des interactions non linéaires entre les variables, ce qui est pertinent pour des phénomènes complexes comme la gravité d'un accident.
- Robustesse au bruit et aux valeurs aberrantes, très fréquentes dans des données réelles.
- Compatibilité avec SHAP, ce qui permet une interprétation fine des facteurs de risque.
- Parallélisation native, réduisant le temps d'entraînement sur un dataset de plus de 400 000 observations.

Ce choix représente donc un bon compromis entre performance, stabilité et explicabilité.

5.2. Split Train/Test

Nous avons séparé les données en deux ensembles :

Train	Test
75% (314 352 obs.)	**25% (104 784 obs.)**

Une **stratification** a été appliquée afin de conserver la même proportion de classes (grave vs non grave) dans les deux sous-échantillons. Cela garantit une évaluation plus fiable du modèle et évite les biais liés à un déséquilibre artificiel des classes dans la phase de test.

5.3. Optimisation Optuna

Pour améliorer les performances du modèle, nous avons réalisé une optimisation d'hyperparamètres à l'aide d'Optuna, un framework moderne basé sur l'optimisation bayésienne.

- Métrique optimisée : F1-score, car notre priorité est la détection correcte des accidents graves.
- Nombre d'essais : 30 trials, ce qui permet une exploration suffisante de l'espace de recherche tout en gardant un temps de calcul raisonnable.

Les meilleurs hyperparamètres obtenus sont :

- *n_estimators = 206*
- *max_depth = 30*
- *min_samples_split = 3*
- *max_features = "log2"*

Ces valeurs renforcent la capacité du modèle à capturer des interactions complexes tout en limitant le surapprentissage grâce à une profondeur contrôlée et un sous-échantillonnage des features.

6. Résultats et Performance

6.1. Métriques

```
Classification Report :
              precision    recall  f1-score   support

           0       0.77      0.78      0.77     47571
           1       0.82      0.80      0.81     57213

    accuracy                           0.79    104784
   macro avg       0.79      0.79      0.79    104784
weighted avg       0.79      0.79      0.79    104784
```

Le modèle Random Forest obtient une accuracy de 79 % et un F1-score de 81 % sur l'ensemble de test.

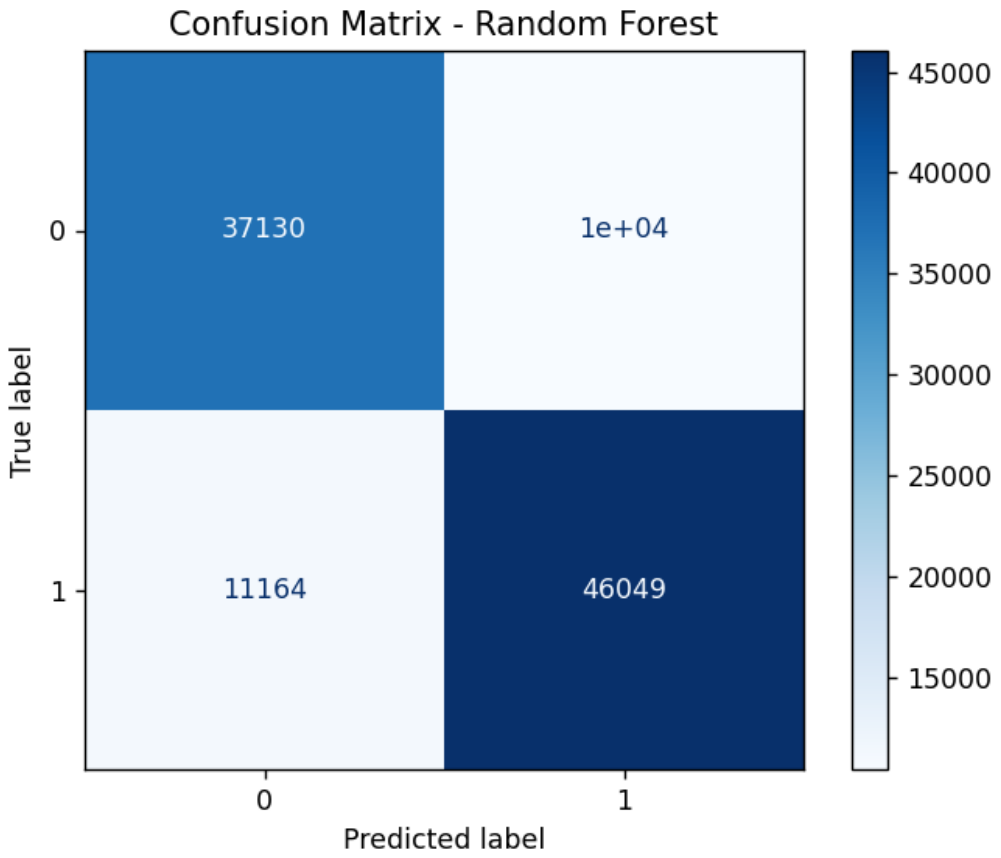
L'accuracy mesure la proportion totale de prédictions correctes, mais le F1-score est ici plus important car il prend en compte l'équilibre entre rappel et précision sur la classe grave.

Un F1-score élevé montre que le modèle parvient à détecter efficacement les accidents sévères, tout en limitant les fausses alertes.

Métrique	Score
Accuracy	**79%**
F1-score	**81%**

6.2. Matrice de Confusion

La matrice de confusion montre la répartition des bonnes et mauvaises prédictions entre les deux classes (grave vs non grave).

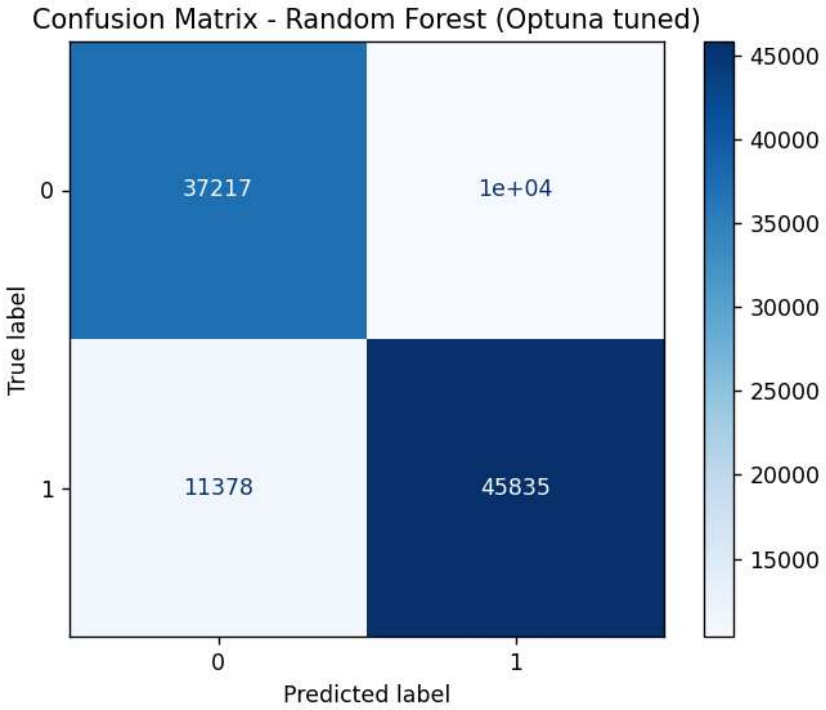


On observe que :

- 46 049 accidents graves sont correctement identifiés,
- 11 164 accidents graves sont manqués,
- 37 130 accidents non graves sont bien classés,
- Environ 10 000 non graves sont prédits comme graves.

Globalement, le modèle détecte bien les accidents graves, ce qui est l'objectif principal du projet.

Les faux positifs (accidents prévus graves alors qu'ils ne le sont pas) restent acceptables : dans une logique de sécurité routière, il vaut mieux sur-évaluer le risque que le sous-estimer, car les conséquences d'un accident grave manqué sont plus critiques qu'une fausse alerte.



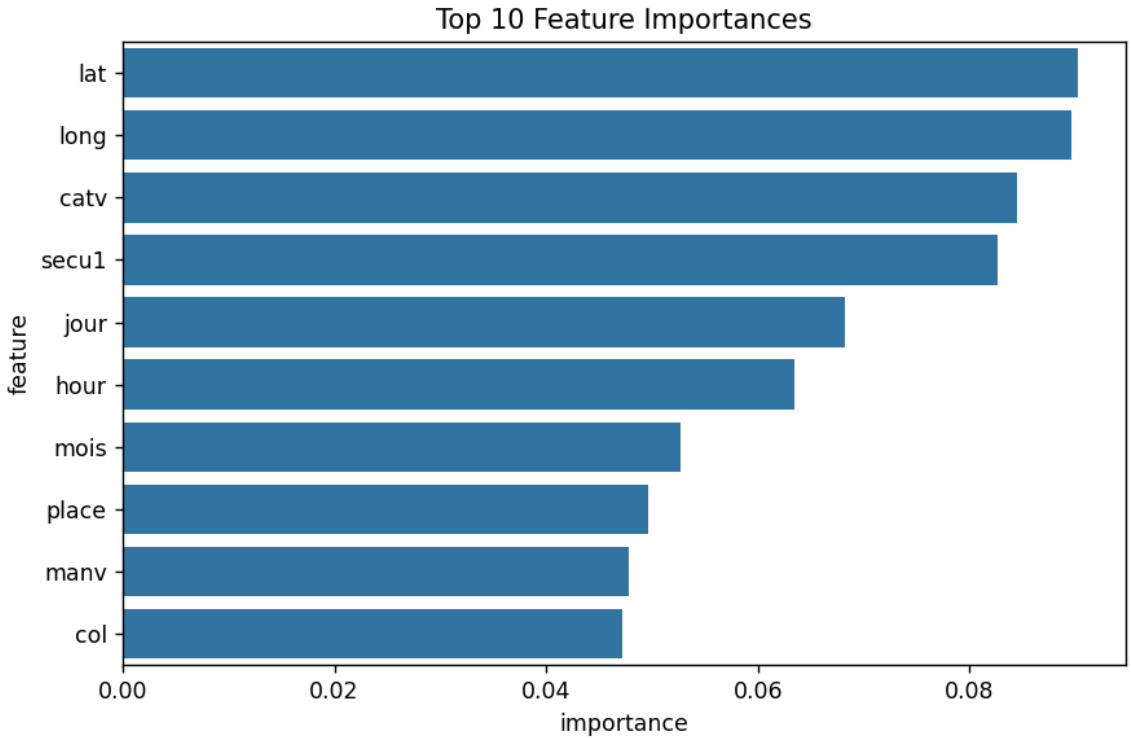
Le modèle optimisé (avec Optuna) identifie correctement la majorité des accidents graves (45 835 vrais positifs).

Le nombre de faux négatifs (11 378) reste raisonnable au vu de la taille du dataset, et les faux positifs restent acceptables dans une logique de sécurité, où il vaut mieux sur-estimer que sous-estimer le risque.

6.3. Feature Importance

L'importance des variables du modèle Random Forest montre clairement quels facteurs influencent le plus la prédiction de la gravité.

```
=== Top Features ===
    feature  importance
18      lat    0.090246
19     long    0.089577
0      catv    0.084485
7     secu1    0.082695
17     jour    0.068274
22     hour    0.063478
16     mois    0.052679
5     place    0.049697
2      manv    0.047863
14      col    0.047242
```



(lat, long) apparaissent en tête, ce qui suggère que certaines zones sont particulièrement accidentogènes ou présentent des conditions routières plus dangereuses.

Viennent ensuite des variables liées à la vulnérabilité physique ou au type de véhicule, comme catv (catégorie du véhicule) et catu (type d'usager), ainsi que secu1 qui indique le port ou non d'un dispositif de sécurité (ceinture, casque).

Dans l'ensemble, les top 4 facteurs sont :

- ***lat*** (latitude),
- ***catv*** (type de véhicule),
- ***long*** (longitude).
- ***secu1*** (port du dispositif de sécurité)

Ces résultats sont cohérents avec les études en sécurité routière, où la protection, le type d'usager (piéton, 2-roues, passager) et le véhicule jouent un rôle majeur dans la gravité des blessures.

7. Interprétabilité SHAP

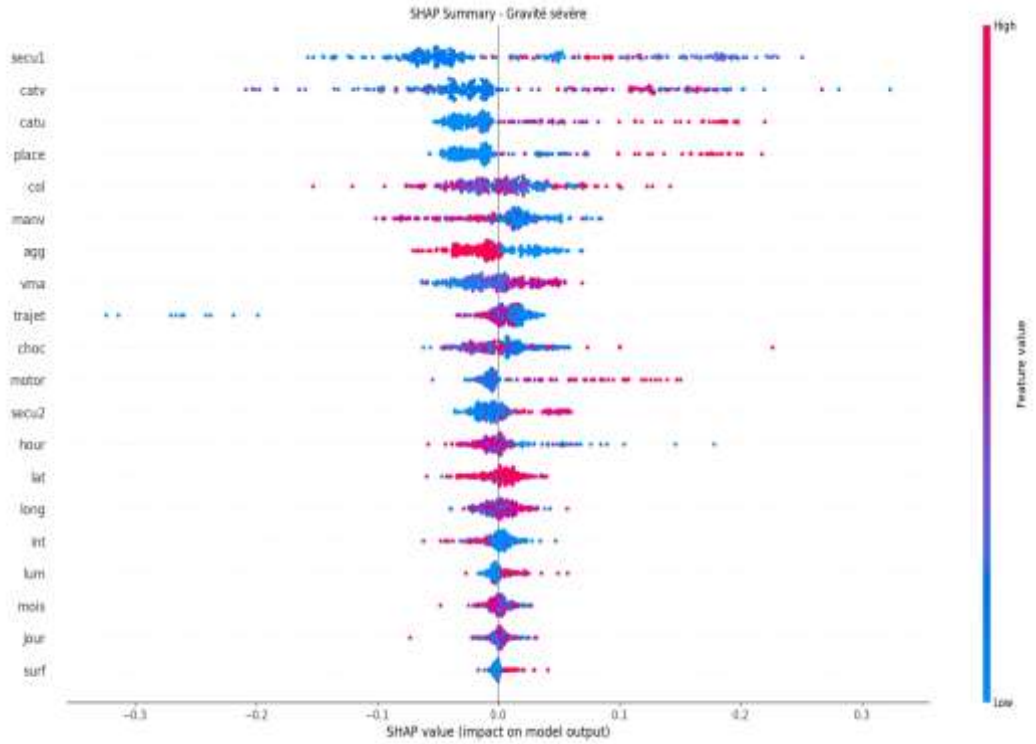
7.1. Principe

La méthode SHAP permet d'expliquer la décision du modèle en calculant l'effet individuel de chaque variable sur la prédiction.

Une valeur SHAP positive signifie que la variable contribue à augmenter la probabilité que l'accident soit classé comme grave, une valeur négative indique l'inverse.

SHAP est particulièrement utile ici car il rend le modèle plus transparent et permet de relier les prédictions à des facteurs explicables par un expert du domaine.

7.2. SHAP Summary



Le graphique SHAP Summary confirme plusieurs tendances importantes :

- Absence de ceinture ou casque (***secu1***) : c'est l'un des facteurs les plus critiques, augmentant fortement la probabilité d'un accident grave.

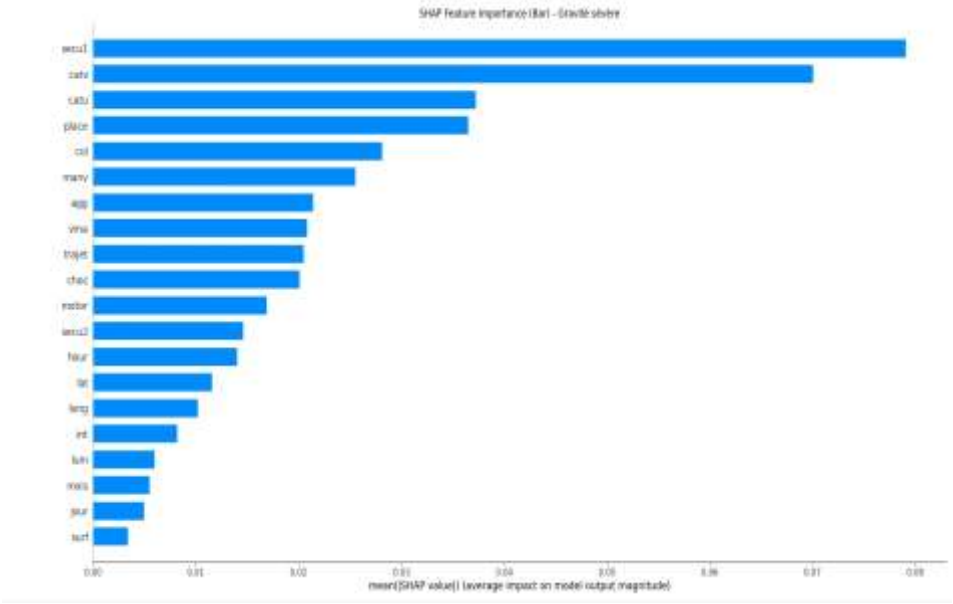
- Types de véhicules (***catv***) : les 2-roues, en particulier, sont nettement plus vulnérables que les véhicules légers.

- Catégorie d'usager (***catu***) : les piétons et deux-roues apparaissent comme les groupes les plus exposés.

- Zones hors agglomération (***agg***) : les vitesses généralement plus élevées entraînent un impact plus violent.

Ces observations montrent que le modèle ne se contente pas d'être performant : il capture des relations réalistes et cohérentes avec les connaissances du domaine.

7.3. SHAP Bar



Le classement SHAP confirme les quatre variables les plus influentes :

- secu1 (sécurité)
- catv (type de véhicule)
- catu (type d'usager)
- place (place assise)

Cela valide la conclusion principale : la vulnérabilité physique et la protection jouent un rôle central dans la sévérité des accidents.

On observe une différence entre l'importance des variables fournie par la Random Forest (***lat, long, catv, secu1***) et celle obtenue avec SHAP (*secu1, catv, catu, place*). Cela s'explique par le fait que la Random Forest met en avant des variables structurantes pour la segmentation, tandis que SHAP met en avant des variables explicatives pour la gravité.

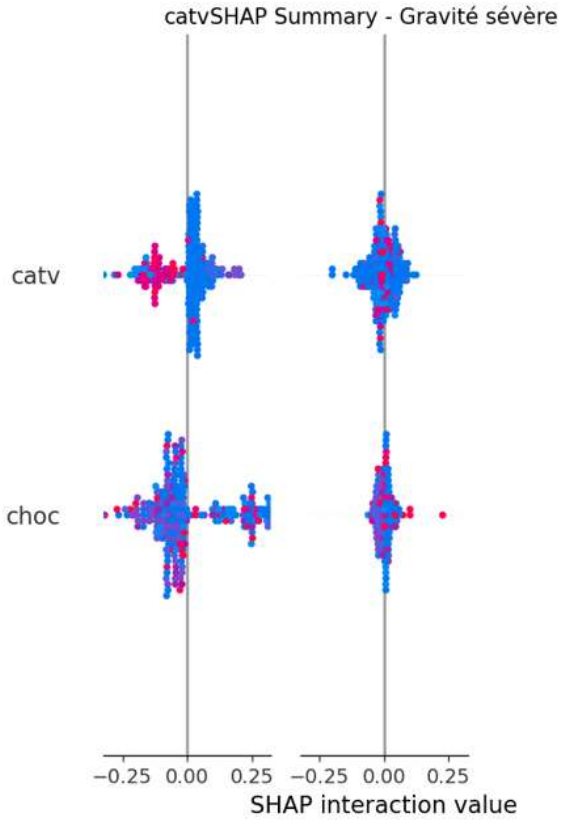
7.4 Interactions SHAP (catv x choc)

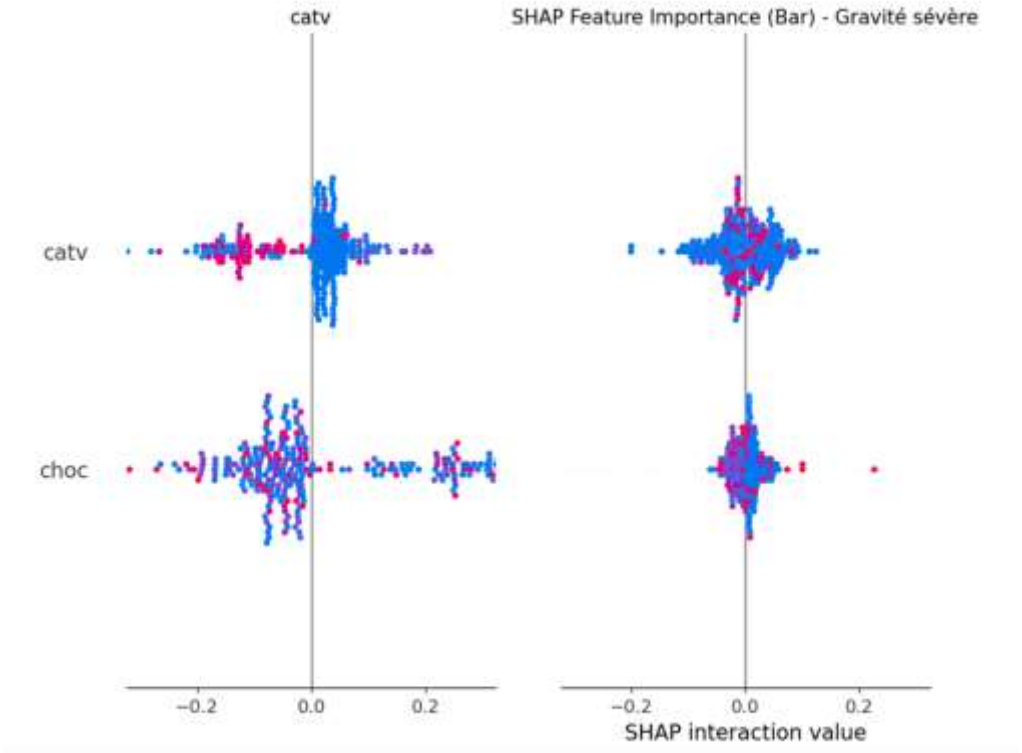
L'analyse des interactions SHAP permet d'observer comment deux variables influencent conjointement la prédiction d'un accident grave. Dans notre cas, l'interaction entre le type de véhicule (catv) et le type de choc (choc) montre que certains couples de situations renforcent le risque.

On voit notamment que les valeurs extrêmes de catv (souvent associées aux 2-roues) combinées à des chocs plus violents produisent des contributions SHAP positives, ce qui indique une augmentation de la probabilité de gravité sévère.

À l’inverse, pour les véhicules plus protégés, les valeurs SHAP restent globalement proches de zéro, même lors de chocs similaires.

Ces deux visualisations confirment que le type de véhicule n’agit pas seul : son influence dépend également de la nature du choc subi.





7.5. Limite catv

La variable catv est codée sous forme numérique, mais ces valeurs ne reflètent pas une échelle réelle : le code “10” ne représente pas un véhicule « plus dangereux » que le code “5”. Ce codage arbitraire peut induire le modèle en erreur.

Pour améliorer la qualité de l’analyse, il serait préférable de :

- regrouper catv en catégories métier (ex. : 2-roues, voitures légères, poids lourds),
- ou d’appliquer un one-hot encoding pour supprimer toute notion d’ordre.

8. Conclusion

Ce projet montre qu'il est possible de prédire la gravité des accidents routiers avec de bonnes performances : 79 % d'accuracy et 81 % de F1-score. Le modèle identifie correctement la majorité des accidents graves, ce qui est crucial dans une logique de prévention.

Les résultats mettent en évidence plusieurs facteurs déterminants : l'absence de dispositifs de sécurité (secu1), la vulnérabilité des usagers (notamment les 2-roues) et l'environnement routier (vitesse, agglomération).

L'utilisation de SHAP a permis de rendre le modèle explicable, un point essentiel pour son adoption par des acteurs institutionnels. À terme, ce type d'outil pourrait aider à cibler les campagnes de prévention, adapter les infrastructures à risque et renforcer les politiques publiques de sécurité routière.